

Semestre : 1 ☐ 2 ☒

Session : Principale ☒ Rattrapage ☐

Etudiant(e):

Nom et Prénom:

Classe:

Module: Machine Learning Appliqué

Classes: 4 SAE, TWIN, INFINI

Enseignante : Equipe Machine Learning Appliqué

Nombre de pages : 5

Documents : NON Autorisé

Internet : NON Autorisé

Date : 21/03/2025

Heure : 10h15

Durée :1h

Merci de répondre ici.

1. Quel est l'objectif principal de la phase de compréhension des objectifs métiers ?

- Définir clairement les hypothèses scientifiques à valider.
- Traduire les problèmes métiers en objectifs techniques mesurables
- Identifier les limites techniques du projet.
- Réaliser un premier prototype de modèle prédictif.

2. Un drone autonome doit apprendre à éviter des obstacles dans un environnement dynamique en maximisant une récompense (survie et efficacité). Quelle technique est pertinente ?

- Classification multiclasse
- Clustering hiérarchique
- Apprentissage par renforcement
- Analyse en composantes principales (ACP)

3. Dans CRISP-DM, quelle phase est axée sur l'interprétation des résultats par rapport aux objectifs métier ?

- Préparation des données
- Modélisation
- Évaluation
- Déploiement

4. Dans un projet basé sur CRISP-DM, une mauvaise définition des objectifs métiers peut entraîner ?

- Un sur-ajustement des modèles prédictifs
- Une mauvaise compréhension des métriques de performance
- Une inefficacité globale dans l'application des résultats obtenus
- Une incapacité à collecter des données pertinentes

5. Quelle est la principale raison de la préparation des données ?

- Accélérer l'entraînement des modèles
- Réduire la complexité algorithmique
- Améliorer la précision des modèles en éliminant les incohérences
- Augmenter la quantité de données disponibles

6. Quelle est la principale différence entre standardisation et normalisation ?

- La standardisation ramène les valeurs entre 0 et 1, tandis que la normalisation les centre autour de zéro
- La standardisation utilise la moyenne et l'écart-type, tandis que la normalisation utilise les valeurs minimales et maximales
- La normalisation est préférable pour les données catégorielles
- La standardisation ne modifie pas l'échelle des valeurs

7. Quelle méthode permet de détecter et de traiter les valeurs aberrantes ?

- L'encodage fréquentiel
- L'analyse de variance
- L'application de transformations logarithmiques
- L'analyse de la distribution statistique des valeurs

8. Pour la méthode KNN, et face à des données bruitées, quel paramètre à ajuster ?

- Diminuer la valeur de k
- Augmenter la valeur de k
- Changer le type de distance.
- Aucun ajustement n'est possible

9. Quelle bibliothèque Python est la plus couramment utilisée pour implémenter KNN ?

- a. TensorFlow
- b. Scikit-learn
- c. OpenCV
- d. Matplotlib

10. Lorsqu'on compare les performances des classificateurs KNN et SVM à l'aide d'une courbe ROC, lequel des éléments suivants est généralement vrai ?

- a. La courbe ROC de SVM est souvent au-dessus de celle de KNN lorsque les données sont non linéairement séparables
- b. La courbe ROC de KNN est toujours au-dessus de celle de SVM, quel que soit le jeu de données
- c. Un AUC plus élevé pour KNN indique que SVM est un meilleur classificateur
- d. La courbe ROC ne peut pas être utilisée pour comparer KNN et SVM

11. Dans KNN, que se passe-t-il si deux classes ont le même nombre de voisins parmi les K plus proches ?

- a. L'algorithme choisit la classe d'une manière non informée
- b. Il prend en compte la distance aux voisins pour départager
- c. Il ignore ces voisins et cherche d'autres voisins
- d. Il considère le point comme un outlier

12. Après avoir exécuter les deux algorithmes SVM et KNN, lequel prendra un temps d'exécution le plus élevé durant la phase d'apprentissage ?

- a. SVM
- b. KNN
- c. Les deux modèles ont le même temps d'exécution
- d. On ne peut pas juger

13. Que se passe-t-il si K, dans KNN, est trop grand ?

- a. Le modèle devient plus précis
- b. L'algorithme devient plus rapide
- c. Le modèle peut inclure des points d'autres classes et être moins performant
- d. Le modèle devient plus sensible au bruit

14. Pourquoi KNN est sensible aux features non pertinentes ?

- a. Car elles influencent le calcul des distances et faussent la classification
- b. Car KNN utilise une approche probabiliste

c. Car KNN effectue une normalisation automatique des features avant de calculer les distances

d. Car il utilise uniquement des features numériques

15. Un algorithme KNN avec K=3 doit classer un nouveau point P dans un espace 2D. On a les points d'entraînement suivants avec leurs classes ?

Point	Coordonnées (x, y)	Classe
A	(2, 3)	Classe 1
B	(5, 5)	Classe 2
C	(6, 8)	Classe 1
D	(3, 4)	Classe 2
E	(7, 7)	Classe 1

Le point P(4,6) doit être classé en utilisant la distance euclidienne. La formule de la distance euclidienne entre deux points x1 et x2 est la suivante

$$\text{Dis}(x_1, x_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

Quelle sera la classe du point P(4,6) pour K=3?

- a. {B, D, E} → Classe 2
- b. {A, C, D} → Classe 1
- c. {B, C, E} → Classe 1
- d. {B, C, D} → Classe 2

16. Un ingénieur en machine learning applique KNN sur un dataset médical afin de prédire si un patient est atteint d'une maladie. Il rencontre plusieurs problèmes

- 1- Certaines caractéristiques ont des unités différentes (ex : âge en années, tension artérielle en mmHg, taux de glucose en g/L)
- 2- Les distances calculées semblent biaisées par certains attributs.
- 3- L'algorithme donne des résultats incohérents même avec une bonne valeur de K

Quelle est la meilleure solution à appliquer ?

- a. Ne rien changer, car KNN fonctionne toujours bien si K est bien choisi
- b. Normaliser les données en appliquant MinMaxScaler
- c. Augmenter le nombre de voisins K pour réduire l'effet des unités différentes
- d. Supprimer les features avec des valeurs trop grandes pour éviter les biais

17. Dans une classification binaire par SVM, un point qui n'est pas un vecteur support signifie que :

- a. Il n'influence pas la position de l'hyperplan optimal
- b. Il est considéré comme un outlier et doit être supprimé

- c. Il contribue directement à l'ajustement des paramètres de noyau
d. Il définit la largeur de la marge autour de l'hyperplan

18. Parmi ces noyaux, lequel est souvent utilisé pour des problèmes de classification non linéaire ?

- a. Noyau linéaire
b. Noyau polynomial
c. Noyau gaussien (RBF)
d. Les réponses b et c

19. Quel est l'impact d'un noyau inadapte sur un SVM ?

- a. Le modèle convergera plus rapidement vers une solution optimale
b. Le modèle risque de ne pas capturer correctement la structure des données, entraînant de mauvaises performances
c. Le nombre de vecteurs supports sera automatiquement réduit
d. Le SVM deviendra linéaire même sur des données non linéaires

20. Si un ensemble de données est parfaitement séparé par un hyperplan, que se passe-t-il avec un SVM linéaire ?

- a. Il trouve plusieurs solutions possibles
b. Il choisit l'hyperplan qui maximise la marge
c. Il échoue à classer correctement les données
d. Il ajuste un modèle non linéaire pour éviter l'overfitting

21. Quel est l'avantage principal du « Kernel Trick » ?

- a. Il réduit la complexité computationnelle
b. Il permet d'utiliser des noyaux de très grande dimension tout en maintenant une efficacité computationnelle.
c. Il empêche l'overfitting
d. Il permet de sélectionner automatiquement le meilleur noyau

22. Quelle méthode est souvent utilisée pour fusionner les sorties des classifieurs en "one vs one" ?

- a. La méthode de vote majoritaire
b. La moyenne des scores de marge
c. La somme pondérée des sorties
d. La sélection du classifieur le plus rapide SVM

23. Quel est le problème associé aux SVM en présence de données bruitées ou d'outliers ?

- a. Ils ignorent automatiquement les outliers
b. Ils peuvent être très sensibles aux outliers, affectant la position de l'hyperplan
c. Ils transforment les outliers en vecteurs supports sans impact
d. Ils éliminent les outliers durant l'entraînement

24. Quel est l'impact principal de la profondeur maximale d'un arbre de décision sur son comportement ?

- a. Une profondeur trop faible peut provoquer un surapprentissage
b. Une profondeur trop grande peut conduire à un sous-apprentissage
c. Une profondeur trop grande peut entraîner un modèle très complexe et sensible au bruit
d. La profondeur maximale n'a aucun effet significatif sur la performance

25. Dans le cadre d'un arbre de décision, quel impact a l'ajout de bruit aux données d'entraînement sur le modèle ?

- a. Il augmente la complexité de l'arbre car des nouvelles divisions seront introduites pour s'adapter aux perturbations
b. Il réduit la profondeur de l'arbre car les décisions deviennent plus évidentes
c. Il force l'arbre à utiliser uniquement les caractéristiques les plus robustes
d. Il n'a aucun effet sur la structure de l'arbre

26. En analysant l'arbre, vous remarquez qu'une caractéristique catégorique est utilisée à plusieurs reprises dans des splits successifs. Pourquoi cela peut-il arriver ?

- a. Cette caractéristique est non corrélée avec la variable cible
b. Cette caractéristique a une forte variance
c. Cette caractéristique est fortement corrélée à la variable cible
d. Cette caractéristique offre une réduction d'impureté élevée à différents seuils

27. Que signifie un indice de Gini proche de 0 pour une variable donnée ?

- a. L'attribut est très impur
b. L'attribut sépare parfaitement les classes
c. L'attribut doit être éliminé
d. L'attribut contient des valeurs manquantes

28. Dans quel cas un arbre de décision pourrait-il être moins performant qu'un modèle linéaire ?

- a. Lorsque les relations entre les variables explicatives et la variable cible sont hautement non linéaires
b. Lorsque les données contiennent de nombreuses variables redondantes
c. Lorsque la séparation entre les classes suit une fonction linéaire parfaite
d. Lorsque l'arbre est très profond et bien ajusté aux données d'apprentissage

29. Vous êtes un data scientifique travaillant sur un modèle de détection de maladies. Vous avez testé votre modèle sur un jeu de données de 200 patients, et obtenu la matrice de confusion suivante :

	Prédit Malade	Prédit Sain
Réel Malade	TP = 80	FN = 20
Réel Sain	FP = 30	TN = 70

Quelle est l'accuracy de ce modèle ?

- a. 72.7%
- b. 25%
- c. 50.6%
- d. 75%

30. Parmi les métriques suivantes, laquelle n'est pas directement calculée à partir de la matrice de confusion ?

- a. Accuracy
- b. Précision
- c. F1-Score
- d. AUC-ROC

31. Qu'indique une courbe ROC proche de la diagonale ?

- a. Un modèle performant avec une excellente discrimination.
- b. Un modèle dont les prédictions sont équivalentes au hasard.


- c. Un modèle surentraîné (sur-apprentissage).
- d. Une précision élevée sur les prédictions positives.

32. Si un arbre de décision a un AUC élevé sur l'ensemble d'apprentissage mais faible sur l'ensemble de test, que peut-on en conclure ?

- a. Le modèle est bien généralisé
- b. Le modèle est en overfitting
- c. Le modèle est en underfitting
- d. L'AUC n'est pas adaptée aux arbres de décision

33. En observant la courbe ci-dessous, qui illustre l'évolution de l'AUC en fonction de la valeur de k, quelle est la valeur optimale de k pour le modèle k-NN ?

- a. k = 5
- b. k = 9
- c. k = 13
- d. k = 17



Mise en situation 1 : Une banque analyse les transactions de ses clients pour détecter d'éventuelles fraudes. Les données brutes contiennent des erreurs et nécessitent une préparation avant l'entraînement d'un modèle de classification.

Problèmes identifiés :

- Certaines transactions contiennent des valeurs manquantes pour la variable "Montant"
- Des valeurs extrêmes sont détectées dans la colonne "Durée de la transaction"
- La colonne "Type de carte" est catégorielle (Visa, MasterCard, Amex)
- La colonne "Localisation" contient des doublons

34. Quelle méthode est la plus appropriée pour traiter les valeurs manquantes dans la colonne "Montant" ?

- a. Supprimer toutes les transactions contenant des valeurs manquantes
- b. Remplacer par la moyenne des montants des transactions
- c. Remplacer par une valeur fixe arbitraire
- d. Ignorer les valeurs manquantes sans traitement

35. Comment gérer les valeurs extrêmes de la colonne "Durée de la transaction" ?

- a. Ajouter des variables
- b. Remplacer les valeurs extrêmes par la médiane des durées
- c. Appliquer une transformation logarithmique pour réduire leur impact
- d. Aucune action n'est nécessaire

36. Quelle est la meilleure méthode pour encoder la colonne "Type de carte" ?

- a. Label Encoding
- b. One-Hot Encoding
- c. Binary Encoding
- d. Remplacement par des valeurs numériques arbitraires

Mise en situation 2 : Une entreprise financière souhaite automatiser l'octroi de crédits en utilisant un **arbre de décision**. Le modèle doit prédire si un client est **éligible** ou **non éligible** à un crédit en fonction de plusieurs critères : Revenu mensuel, Score de crédit, Historique de remboursement, Nombre de crédits en cours, et Durée demandée pour le prêt

Après avoir construit un premier modèle, l'équipe de data science observe plusieurs problèmes :

1. L'arbre est très profond, ce qui le rend difficile à interpréter.
2. Il classe mal certains clients avec un score de crédit moyen.
3. Les décisions prises par le modèle sont instables : un petit changement dans les données entraîne des structures d'arbre très différentes.

L'objectif est d'optimiser cet arbre de décision pour améliorer sa robustesse, sa précision et son interprétabilité.

37. Pourquoi un arbre de décision peut-il devenir trop profond et complexe ?

- a. Parce qu'il essaie de séparer parfaitement toutes les observations
- b. Parce qu'il est sensible aux valeurs aberrantes
- c. Parce qu'il est construit en utilisant uniquement des variables continues
- d. Parce que son critère d'arrêt est basé sur une fonction de coût d'erreur

38. Quelle mécanique est souvent utilisée pour éviter la fragmentation excessive des données dans un arbre de décision ?

- a. Fixer une profondeur maximale pour l'arbre
- b. Utiliser un critère de pureté strict comme Gini
- c. Normaliser les données avant l'entraînement
- d. Ajouter des caractéristiques aléatoires au modèle

39. L'équipe observe que l'arbre est instable et change fortement lorsqu'on le réentraîne avec de nouvelles données légèrement différentes. Quelle est la cause principale de ce problème ?

- a. L'utilisation de trop peu de variables explicatives
- b. Le fait que les arbres de décision sont sensibles aux petites variations dans les données
- c. L'utilisation d'un critère de division inadéquat (Gini vs Entropie)
- d. L'absence de normalisation des variables continues

40. Pourquoi un arbre de décision est-il généralement moins performant sur des données non vues par rapport à un autre modèle ?

- a. Parce qu'il a tendance à mémoriser les données d'entraînement sans généraliser
- b. Parce qu'il ne peut pas gérer des variables catégorielles
- c. Parce qu'il ne peut pas modéliser des relations non linéaires entre les variables
- d. Parce qu'il nécessite toujours un grand volume de données pour fonctionner correctement

Bon Travail !